

Evaluación de la Experiencia de Usuario en Interfaces Adaptativas y Conversacionales Impulsadas por IA: Una Revisión Sistemática de Literatura

Martinez Fuentes, Kenny Danny¹; Guerrero Falla, Christian Angelo¹; Vergara Pachas, Jose Luis¹; Motta Chumbe, JeanPierre D'Angelo¹; Triveño Daza, Felipe¹; Sernaque Gutierrez, Jose¹

¹ Facultad de Ingeniería de Sistemas e Informática, Universidad Nacional Mayor de San Marcos, Lima, Perú

1. Introducción

En los últimos años, la adopción ubicua de agentes conversacionales impulsados por inteligencia artificial parece haber transformado sustancialmente la interacción humano-computadora [1]. Diversas investigaciones empíricas indican que estos sistemas interactivos se han integrado de manera progresiva en dominios críticos como la educación, la atención médica y el servicio al cliente [2]. Se sugiere que la capacidad de las máquinas para simular diálogos intuitivos agiliza tareas complejas y fomenta un uso continuo por parte de los individuos [3]. Esta rápida penetración tecnológica ha modificado el panorama del diseño, desplazando progresivamente el enfoque desde las interfaces gráficas unidimensionales hacia entornos predominantemente conversacionales. Por consiguiente, comprender de manera estructurada cómo las personas experimentan estas interacciones dinámicas resulta fundamental para garantizar la viabilidad de la tecnología a largo plazo [1].

Frente a esta adopción masiva, el estado del arte sugiere la reconceptualización de la calidad de la interacción como un constructo de alta complejidad multidimensional [4]. A diferencia del software tradicional centrado de forma exclusiva en la usabilidad pragmática, la experiencia del usuario frente a la inteligencia artificial involucra respuestas relacionales, cognitivas y afectivas que se co-construyen en tiempo real [5]. Los investigadores coinciden en que los elementos subyacentes del diseño operan frecuentemente como señales sociales críticas que moldean directamente la percepción humana [6]. Por ejemplo, se ha argumentado que el tiempo de latencia influye de manera directa en la credibilidad percibida y en el establecimiento de la confianza durante el diálogo [6]. Asimismo, factores abstractos como la transparencia y la presencia social parecen constituir dimensiones de primer orden para lograr un éxito conversacional sostenido [4]. Por lo tanto, evaluar la eficacia de un agente interactivo exige enfoques teóricos integrales que trasciendan el análisis de las métricas puramente técnicas.

Para abordar esta complejidad, la comunidad científica explora diversas aproximaciones metodológicas destinadas a comprender el impacto de estas interfaces de manera exhaustiva. La naturaleza dual de los agentes conversacionales, que combinan arquitecturas algorítmicas con interfaces de lenguaje natural, requiere una evaluación que abarque tanto el comportamiento del sistema como la respuesta humana [7]. En este sentido, la literatura muestra esfuerzos simultáneos por medir la eficiencia predictiva de los modelos a la par de investigaciones enfocadas en

capturar las actitudes subjetivas de los usuarios. Estos análisis de percepción se ejecutan frecuentemente a través de experimentos controlados en laboratorio o mediante despliegues a pequeña escala [8]. En consecuencia, se asume que campos como la ingeniería de software, la lingüística y la psicología deben converger metodológicamente para establecer parámetros de medición adecuados.

2. Problema de investigación

A pesar de la rápida adopción de agentes conversacionales en múltiples dominios, la evidencia empírica respecto a su evaluación exhibe una notable fragmentación metodológica. La literatura indica que el campo carece de marcos unificados que integren el rendimiento algorítmico con las dimensiones holísticas percibidas por el ser humano [4]. En consecuencia, esta falta de cohesión dificulta la comprensión sistemática de los factores que determinan la efectividad del diálogo interactivo, revelando una serie de vacíos empíricos concurrentes:

- **Carencia de instrumentos nativos e integrales:** La medición de estos sistemas se apoya frecuentemente en escalas genéricas de software (como SUS) que resultan insuficientes para capturar las particularidades dinámicas del diálogo mediado por inteligencia artificial [5, 9, 7, 1, 4].
- **Limitaciones algorítmicas frente a la complejidad del contexto:** Las interfaces inteligentes aún presentan dificultades para procesar matices lingüísticos y mantener un contexto sostenido durante interacciones complejas [3, 1, 2].
- **Dificultad en la consolidación de alianzas socio-afectivas:** Numerosos sistemas exhiben una capacidad limitada para proyectar empatía genuina o mitigar el efecto de novedad, obstaculizando el establecimiento de vínculos de confianza a largo plazo [1, 10, 2].
- **Opacidad ética y falta de explicabilidad:** La carencia de explicaciones claras sobre la lógica interna del sistema socava la transparencia de la interacción y recalibra negativamente la confianza del individuo [8, 4].
- **Inconsistencia en la adaptabilidad demográfica e inclusión:** El diseño de estas interfaces frecuentemente ignora la variabilidad en las necesidades cognitivas de diferentes grupos poblacionales, requiriéndose diseños verdaderamente inclusivos [3, 9, 4, 6].

3. Objetivo del estudio

El objetivo principal de esta revisión sistemática de literatura es analizar y sintetizar el estado del arte respecto a las metodologías, instrumentos y métricas utilizadas para evaluar la Experiencia del Usuario (UX) en sistemas interactivos modernos, con especial énfasis en agentes conversacionales impulsados por inteligencia artificial. Para dar respuesta a la fragmentación metodológica identificada, este estudio persigue tres propósitos específicos:

En primer lugar, busca identificar los enfoques de medición empírica predominantes, distinguiendo entre la aplicación de escalas genéricas de evaluación de software y el desarrollo de instrumentos nativos. Asimismo, examina cómo la literatura actual articula la medición del rendimiento algorítmico (como el procesamiento de lenguaje natural y los tiempos de latencia) con las dimensiones holísticas de la percepción humana (aspectos socio-afectivos, cognitivos y éticos). Finalmente, busca evidenciar las principales limitaciones estructurales en las prácticas de evaluación vigentes.

4. Preguntas de investigación

Para estructurar el alcance metodológico de esta revisión sistemática y fundamentar la formulación de las interrogantes de manera rigurosa, se adoptó el marco de trabajo PICOC (Población, Intervención, Comparación, Resultados y Contexto). La definición de estas dimensiones permitió establecer parámetros de búsqueda y criterios de inclusión precisos antes de la extracción de datos empíricos:

- **Población (P) y Contexto (C):** El alcance del estudio se delimita a los agentes conversacionales e interfaces adaptativas impulsadas por Inteligencia Artificial. El contexto de análisis se circunscribe a los entornos de interacción moderna humano-computadora, donde el sistema actúa como un ente colaborativo y dinámico.
- **Intervención (I) y Comparación (C):** La intervención central radica en la aplicación empírica de metodologías para la evaluación de la Experiencia de Usuario. El eje comparativo busca contrastar la utilización de escalas genéricas (heredadas del diseño de software tradicional) frente a la adopción progresiva de instrumentos de evaluación nativos (diseñados específicamente para interacciones basadas en algoritmos generativos y de procesamiento de lenguaje natural).
- **Resultados Esperados - Outcomes (O):** La síntesis de la literatura busca identificar la articulación existente entre las métricas de rendimiento técnico y la percepción humana. Asimismo, se pretende evaluar el abordaje de la explicabilidad ética y consolidar un mapeo estructurado de las brechas metodológicas vigentes en el campo de estudio.

A partir de la delimitación exhaustiva proporcionada por este marco metodológico, se plantearon las siguientes cuatro preguntas clave. Estas actuarán como el eje conductor para la extracción de datos y la síntesis de la evidencia empírica:

- **RQ1:** ¿Qué escalas de medición (genéricas o nativas) se utilizan con mayor frecuencia para evaluar la UX en agentes conversacionales?
- **RQ2:** ¿Qué métricas se emplean para articular el rendimiento técnico del algoritmo con las dimensiones cognitivas y socio-afectivas del usuario?
- **RQ3:** ¿Cómo aborda la literatura actual la evaluación de aspectos como la explicabilidad ética y la adaptabilidad demográfica?
- **RQ4:** ¿Cuáles son las principales limitaciones metodológicas y vacíos de diseño reportados en las prácticas de evaluación vigentes?

5. Antecedentes / Marco teórico

A continuación se definirán conceptos clave:

5.1 Definiciones clave y conceptos principales

Para comprender adecuadamente el alcance de esta revisión sistemática y la complejidad que implica evaluar la interacción humano-computadora moderna, es preciso definir los conceptos fundamentales que estructuran este dominio tecnológico:

- **Agentes Conversacionales e Interfaces Adaptativas:** Los agentes conversacionales (frecuentemente denominados chatbots) son sistemas interactivos impulsados por inteligencia artificial que simulan diálogos intuitivos para asistir a los usuarios en diversas tareas [1]. Estos sistemas se han integrado progresivamente en dominios críticos como la educación y el servicio al cliente, y poseen una naturaleza dual al combinar arquitecturas algorítmicas con interfaces de lenguaje natural [7, 2].
- **Experiencia del Usuario (UX) Multidimensional en IA:** A diferencia del software tradicional centrado de forma exclusiva en la usabilidad pragmática, la interacción con inteligencia artificial redefine la calidad como un constructo de alta complejidad multidimensional [4]. En este contexto, la UX abarca no solo la eficiencia técnica, sino que involucra respuestas relacionales, cognitivas y afectivas que el individuo co-construye en tiempo real con la máquina [5].
- **Señales Sociales y Vínculos de Confianza:** En los entornos conversacionales, los elementos subyacentes del diseño operan frecuentemente como señales sociales críticas que moldean directamente la percepción humana [6]. Factores como el tiempo de latencia influyen de manera directa en la credibilidad percibida y la confianza [6], mientras que la falta de empatía o presencia social dificulta la consolidación de alianzas socio-afectivas [10, 4].
- **Explicabilidad Ética y Transparencia:** Se refiere a la capacidad de estas tecnologías para proporcionar justificaciones claras y verificables sobre la lógica interna empleada al emitir sugerencias o procesar información [8]. La carencia de esta explicabilidad socava la transparencia ética de la interacción y recalibra negativamente la confianza del individuo frente a la autonomía del modelo algorítmico [4].

- **Evaluación Nativa de UX Conversacional:** Comprende la necesidad empírica de utilizar instrumentos y métricas diseñados específicamente (de forma nativa) para medir interacciones mediadas por inteligencia artificial [9]. La aplicación de escalas genéricas de software (como SUS) resulta insuficiente para capturar las particularidades dinámicas del diálogo [5, 7].

5.2 Tecnología y metodología principal

La literatura reciente muestra que la evaluación de la experiencia del usuario (UX) en sistemas interactivos modernos se articula principalmente alrededor de dos núcleos tecnológicos: los agentes conversacionales y las interfaces adaptativas. En el caso de los chatbots, la base metodológica y tecnológica se sustenta en módulos de procesamiento de entrada, comprensión del lenguaje natural (NLU), gestión del diálogo y generación dinámica de respuestas. Esta arquitectura demuestra que la UX en estos sistemas trasciende la interfaz gráfica tradicional, dependiendo fundamentalmente de la integración entre la capa conversacional y los mecanismos internos que interpretan intenciones, extraen información contextual y producen respuestas coherentes con la tarea del individuo [1, 8, 2].

De forma complementaria, en las interfaces adaptativas e inteligentes, la metodología principal se apoya en mecanismos capaces de captar información del comportamiento y del estado cognitivo del usuario para ajustar la interacción en tiempo real. La evidencia empírica indica que estas interfaces incorporan frecuentemente recursos de reconocimiento de estados afectivos y biometría espacial mediante hardware de captura sensorial [7]. Desde una perspectiva metodológica, la literatura revisada demuestra una clara preferencia por enfoques de evaluación centrados en el usuario, predominando los estudios empíricos de interacción, la validación de instrumentos específicos para entornos dialógicos y los mapeos sistemáticos [5, 9, 4].

5.3 Modelos y algoritmos más utilizados

En relación con los modelos y algoritmos que estructuran la interacción en estos sistemas, la literatura identifica una transición progresiva desde enfoques fundamentados en reglas lógicas hacia arquitecturas impulsadas por datos. Entre los más utilizados destacan:

5.3.1 Sistemas basados en reglas:

Enfoques tradicionales utilizados frecuentemente en dominios acotados o educativos, que emplean flujos conversacionales deterministas y árboles de decisión simples. Aunque ofrecen control sobre la secuencia de interacción, su capacidad de adaptación es severamente limitada ante desviaciones del guión preestablecido por el usuario [2].

5.3.2 Procesamiento y Comprensión del Lenguaje Natural:

Modelos fundamentales para la clasificación probabilística de intenciones y el reconocimiento de entidades nombradas.

Permiten a los agentes conversacionales inferir el contexto semántico y la continuidad conversacional de forma dinámica, sin depender exclusivamente de rutas de diálogo fijas [1, 8].

5.3.3 Redes Neuronales y Aprendizaje Profundo:

Arquitecturas avanzadas, que incluyen modelos neuronales de extremo a extremo y transformadores, orientadas a la generación de respuestas. Estas técnicas optimizan la coherencia conversacional, la generalización y la sensibilidad al contexto en tiempo real, superando ampliamente a los enfoques puramente estadísticos [1].

5.3.4 Aprendizaje por Refuerzo y Grafos de Conocimiento:

Algoritmos integrados frecuentemente en sistemas de alta complejidad, como los recomendadores conversacionales. Permiten al sistema actualizar preferencias dinámicamente, seleccionar la acción conversacional óptima siguiente y sostener diálogos más informados y explicables [8].

5.3.5 Algoritmos de Clasificación y Modelos Bayesianos:

Métodos como el aprendizaje supervisado, no supervisado y redes bayesianas, ampliamente utilizados en interfaces adaptativas generales para procesar datos multimodales (por ejemplo, biometría o reconocimiento de estados afectivos). Su selección algorítmica depende directamente de la modalidad de la señal procesada y del nivel de autonomía esperado del sistema [7].

5.4 Métricas de evaluación

Para evaluar la Experiencia del Usuario (UX) en sistemas interactivos modernos y agentes conversacionales, la literatura analizada evidencia la necesidad de superar las mediciones puramente computacionales para integrar el rendimiento algorítmico con la percepción humana. De acuerdo con el estado del arte, las prácticas de evaluación vigentes se estructuran en torno a los siguientes enfoques y métricas:

- **Métricas Subjetivas Genéricas (Limitaciones de la línea base):** Tradicionalmente, la medición de estos sistemas se ha apoyado en escalas genéricas de evaluación de software, como el System Usability Scale (SUS). Sin embargo, múltiples estudios coinciden en que estas métricas, centradas exclusivamente en la usabilidad pragmática, resultan insuficientes para capturar las particularidades dinámicas, relacionales y multidimensionales del diálogo mediado por inteligencia artificial [5, 9, 7, 4].
- **Métricas Subjetivas Nativas e Integrales:** Ante la insuficiencia de las escalas gráficas tradicionales, la literatura subraya la urgencia de aplicar herramientas estandarizadas y diseñadas de manera nativa para contextos conversacionales. Estas métricas evalúan la calidad de la interacción como un constructo holístico, capturando las respuestas relacionales, cognitivas y afectivas que el usuario co-construye en tiempo real, así como dimensiones abstractas de primer orden como la transparencia, la empatía y la presencia social del agente [5, 1, 4].

- **Métricas de Rendimiento Técnico y Latencia:** En paralelo a la percepción subjetiva, se emplean métricas computacionales y pruebas algorítmicas fuera de línea (offline) para medir la eficiencia predictiva de los modelos. Dentro de esta categoría, destaca la medición del tiempo de latencia (tiempo de respuesta del sistema). La evidencia empírica demuestra que esta métrica técnica opera como una señal social crítica que influye de manera directa en la credibilidad percibida, la adaptabilidad demográfica y el establecimiento de vínculos de confianza a largo plazo durante el diálogo [8, 6].

5.5 Tecnologías relacionadas

La evaluación y el diseño centrado en el usuario de estas interfaces requieren el apoyo de infraestructuras tecnológicas que faciliten tanto la comprensión del contexto como la simulación de la interacción. Como complemento a las arquitecturas algorítmicas, la literatura especializada destaca el uso de las siguientes tecnologías de soporte:

- **Prototipado “Wizard-of-Oz”:** Técnica metodológica utilizada para simular la inteligencia de una interfaz conversacional en fases tempranas de evaluación. Consiste en utilizar a un operador humano para generar las respuestas del sistema de forma no intrusiva, permitiendo evaluar la fluidez del flujo de trabajo y la experiencia del usuario antes del desarrollo técnico completo del algoritmo.
- **Modelado de Ontologías y Sistemas Sensibles al Contexto (CARS):** Estructuras tecnológicas utilizadas para formalizar y procesar información contextual (como la identidad del usuario, el tiempo y el entorno) en tiempo real. Estas arquitecturas semánticas se integran con sistemas de recomendación para generar Interfaces de Usuario Adaptativas (AUI) que reducen la carga cognitiva al personalizar dinámicamente los servicios presentados.
- **Técnicas de Ajuste Fino (Fine-Tuning) para LLMs:** Procesos de entrenamiento adicional aplicados a Modelos de Lenguaje de Gran Escala. Se emplean para superar las limitaciones de los chatbots basados en aprendizaje supervisado tradicional, ajustando las respuestas a contextos específicos para manejar lenguaje informal, resolver consultas complejas y lograr interacciones más naturales y fluidas con el usuario.

5.6 Estudios previos relacionados

La transición de las interfaces gráficas de usuario (GUI) tradicionales hacia agentes conversacionales impulsados por inteligencia artificial (IA) ha requerido una reevaluación fundamental de los métodos de medición empírica. La literatura académica evidencia que la experiencia del usuario (UX) en estos sistemas es un constructo multidimensional, el cual abarca respuestas cognitivas, relacionales y socioafectivas co-construidas en tiempo real entre el humano y la máquina. A partir del escrutinio de las investigaciones recientes, se identifican las siguientes tendencias y deficiencias metodológicas en la evaluación empírica de estas tecnologías.

5.6.1 Evolución de las métricas: De la usabilidad genérica a las escalas nativas:

Históricamente, la evaluación de software se ha apoyado en instrumentos genéricos como la System Usability Scale (SUS). Sin embargo, diversos estudios han demostrado que estas métricas estáticas fracasan al intentar capturar las propiedades dinámicas del diálogo mediado por IA, como la toma de turnos, la coherencia del contexto y la adecuación semántica.

- **Desarrollo de escalas nativas:** Para solucionar esta limitación, se desarrollaron herramientas como la Chatbot Usability Scale (BUS). Su versión optimizada, el BUS-11, consolidó un modelo estadísticamente estable que agrupa dimensiones de funcionalidad, calidad de la conversación, accesibilidad y tiempos de respuesta [5, 9].
- **Adaptabilidad demográfica:** La validación de estas escalas reveló que la percepción de usabilidad no es homogénea; por ejemplo, las cohortes de mayor edad califican sistemáticamente las interacciones como menos satisfactorias, lo que subraya diferencias generacionales en la carga cognitiva tolerada [9, 6].

5.6.2 Evaluación empírica en dominios críticos de aplicación:

La implementación de interfaces adaptativas y conversacionales ha sido objeto de exhaustivas evaluaciones experimentales en distintos sectores, revelando resultados contrastantes:

- **Sistemas de Recomendación Conversacional (CRS):** La evaluación ha dependido históricamente de métricas matemáticas de precisión offline, asumiendo erróneamente que una mayor exactitud algorítmica equivale a una mejor UX. La irrupción de los Modelos de Lenguaje de Gran Escala (LLMs) ha introducido problemas críticos de “opacidad epistémica” (falta de explicabilidad algorítmica), verbosidad y alucinaciones, exigiendo a la academia migrar hacia metodologías que auditen la transparencia y la confianza a nivel de turno [8].
- **Educación y el modelo CHISM:** Los chatbots educativos funcionan como tutores o pares de estudio, demostrando mejoras significativas en el aprendizaje mediante instrucción personalizada. El uso de marcos multidimensionales como CHISM ha permitido documentar la reducción de la ansiedad en los alumnos. Sin embargo, también expone barreras como el “valle inquietante” (la interacción se siente perturbadoramente vacía por la falta de conciencia emocional genuina) [2].
- **Salud y el “techo perceptivo” de la empatía:** En intervenciones clínicas, el éxito depende de la capacidad del sistema para forjar una “alianza terapéutica”. Estudios rigurosos demostraron que, aunque la IA aplique técnicas complejas como la Entrevista Motivacional, los usuarios reconocen simultáneamente su mecanicidad. Esto genera un “techo perceptivo” empático, donde la artificialidad del agente neutraliza el potencial persuasivo a largo plazo [10].

5.6.3 La latencia algorítmica como señal social crítica:

A diferencia de las interfaces gráficas clásicas, donde un tiempo de respuesta tendiente a cero es el estándar ideal de eficiencia, en la IA conversacional la latencia opera como una señal social persuasiva.

- **Asimetría intergeneracional:** Las investigaciones experimentales han revelado que los adultos mayores prefieren interactuar con sistemas que incorporan retrasos algorítmicos controlados, ya que esto simula la cadencia de la reflexión humana real y consolida la credibilidad. En contraste, los adultos jóvenes priorizan la inmediatez pragmática y la sincronización instantánea. Esto invalida los enfoques de diseño de “talla única” y exige interfaces demográficamente adaptables [6].

5.6.4 Síntesis de vacíos de investigación y limitaciones metodológicas:

El escrutinio crítico de la literatura actual expone una serie de vacíos estructurales que justifican la urgencia de reestructurar los métodos de evaluación empírica:

1. Dependencia de encuestas retrospectivas (Post-Hoc): Evaluar la experiencia únicamente al final de las sesiones diluye la granularidad temporal. Existe una carencia crónica de métricas afectivas a nivel de turno (“turn-level UX metrics”) que permitan entender qué fallos específicos del diálogo alteraron el estado psicológico del usuario.
2. Miopía cultural y sobre-representación: Las pruebas empíricas se centran desproporcionadamente en demografías occidentales y universitarias, limitando severamente la comprensión sobre cómo distintos contextos socioculturales procesan el compañerismo algorítmico.
3. Escasez de validaciones longitudinales: La evaluación suele realizarse en experimentos controlados de corta duración. Esto impide analizar cómo el usuario tolera las caídas del sistema a mediano plazo o cómo se disipa el “efecto de novedad” una vez que la herramienta se convierte en un utilitario diario.
4. Desconexión entre algoritmos y UX: Persiste una brecha teórica donde los modelos de caja negra (LLMs) son optimizados mediante métricas estadísticas cerradas, marginando el impacto negativo que la verbosidad y las invenciones factuales tienen sobre la confianza humana en escenarios de uso real.

5.7 Diferencia entre esta RSL y revisiones anteriores

Las investigaciones previas han sentado bases teóricas y metodológicas de gran valor en el ámbito de la interacción humano-computadora mediada por inteligencia artificial. Para comprender la evolución de esta línea de investigación, resulta fundamental delimitar cómo la presente Revisión Sistemática de Literatura (RSL) se articula, complementa y expande los horizontes de los estudios de referencia más cercanos.

La distinción estructural y metodológica de esta RSL se concibe como una progresión natural de los estudios previos, consolidada a través de tres ejes comparativos fundamentales:

- **Ampliación del ecosistema tecnológico:** Los trabajos previos establecieron hitos importantes; uno validó con éxito la psicometría y adaptación lingüística de la Chatbot Usability Scale, mientras que otro proporcionó un marco teórico robusto para la calidad dialógica. Construyendo sobre estos aportes, la presente RSL unifica ambos mundos, abarcando simultáneamente los agentes basados en procesamiento de lenguaje natural y las interfaces de usuario inteligentes (IUI/AUI).
- **Articulación de la dualidad técnico-perceptiva:** Mientras que los estudios anteriores abordaron con gran profundidad la optimización técnica y la evaluación de la satisfacción del usuario como dimensiones valiosas en sí mismas, esta investigación avanza hacia su intersección. Se analiza explícitamente cómo parámetros computacionales específicos (como la latencia algorítmica y la verbosidad) actúan como señales sociales determinantes en tiempo real.
- **Sistematización metodológica global:** Las publicaciones previas aportaron marcos conceptuales indispensables y validaciones sólidas de campo. Esta RSL complementa dichos esfuerzos implementando un protocolo estructurado bajo las directrices de Kitchenham y PRISMA, lo que permite mapear de manera global las tendencias actuales y complementar los hallazgos demográficos previos.

En conclusión, esta Revisión Sistemática de Literatura actúa como una evolución natural e integradora de los esfuerzos previos. Su propósito es reconciliar y consolidar los avances logrados en el rendimiento de los algoritmos de última generación con las dimensiones socioafectivas, éticas y demográficas del usuario, sentando así las bases para directrices de evaluación unificadas a nivel global.

6. Justificación de la revisión

La presente revisión sistemática de literatura contribuye a estructurar y sintetizar el conocimiento empírico actualmente fragmentado sobre la evaluación de la Experiencia del Usuario (UX) en agentes conversacionales e interfaces adaptativas. A pesar de la adopción masiva de estas tecnologías en dominios críticos, la literatura carece de marcos metodológicos unificados que integren de manera efectiva el rendimiento técnico de los algoritmos con las dimensiones cognitivas y socio-afectivas del ser humano.

Por ello, este estudio resulta fundamental para exponer las limitaciones de utilizar herramientas genéricas de usabilidad en entornos dialógicos y subrayar la necesidad de instrumentos de medición nativos. Asimismo, esta revisión proporciona una base teórica rigurosa para investigadores, ingenieros de software y diseñadores de interfaces interesados en desarrollar evaluaciones empíricas verdaderamente integrales. Al consolidar la evidencia sobre cómo se articulan las métricas computacionales (como la latencia) con factores humanos (como la confianza, la

explicabilidad ética y la inclusión demográfica), esta investigación busca facilitar el diseño de directrices estandarizadas que permitan garantizar la creación de futuros sistemas interactivos que no solo sean técnicamente eficientes, sino también empáticos, transparentes y centrados genuinamente en el usuario.

7. Referencias

- [1] Følstad, A., Araujo, T., Law, E., Brandtzaeg, P., Papadopoulos, S., Reis, L., et al. (2021). Future directions for chatbot research: An interdisciplinary research agenda. *Computing*, 103, 2915–2942. <https://doi.org/10.1007/s00607-021-01016-7>
- [2] Kuhail, M. A., Alturki, N., Alramlawi, S., & Alhejori, K. (2022). Interacting with educational chatbots: A systematic review. *Education and Information Technologies*, 28, 973–1018. <https://doi.org/10.1007/s10639-022-11177-3>
- [3] Belda-Medina, J., & Kokošková, V. (2023). Integrating chatbots in education: Insights from the Chatbot-Human Interaction Satisfaction Model (CHISM). *International Journal of Educational Technology in Higher Education*, 20, 1–20. <https://doi.org/10.1186/s41239-023-00432-3>
- [4] Marconi, L., Longo, L., & Cabitza, F. (2026). Assessing interaction quality in human–AI dialogue: An integrative review and multi-layer framework for conversational agents. *Machine Learning and Knowledge Extraction*. <https://doi.org/10.3390/make8020028>
- [5] Borsci, S., Malizia, A., Schmettow, M., Van Der Velde, F., Tariverdiyeva, G., Balaji, D., & Chamberlain, A. (2021). The Chatbot Usability Scale: The design and pilot of a usability scale for interaction with AI-based conversational agents. *Personal and Ubiquitous Computing*, 26, 95–119. <https://doi.org/10.1007/s00779-021-01582-9>
- [6] Wang, Y.-L., & Lo, C.-W. (2025). The effects of response time on older and young adults' interaction experience with chatbot. *BMC Psychology*, 13. <https://doi.org/10.1186/s40359-025-02459-9>
- [7] Brdnik, S., Heričko, T., & Šumak, B. (2022). Intelligent user interfaces and their evaluation: A systematic mapping study. *Sensors*, 22. <https://doi.org/10.3390/s22155830>
- [8] Jannach, D. (2022). Evaluating conversational recommender systems. *Artificial Intelligence Review*, 56, 2365–2400. <https://doi.org/10.1007/s10462-022-10229-x>
- [9] Borsci, S., Schmettow, M., Malizia, A., Chamberlain, A., & Van Der Velde, F. (2022). A confirmatory factorial analysis of the Chatbot Usability Scale: A multilanguage validation. *Personal and Ubiquitous Computing*, 27, 317–330. <https://doi.org/10.1007/s00779-022-01690-0>
- [10] He, L., Basar, E., Wiers, R. W., Anthéunis, M. L., & Krahmer, E. (2022). Can chatbots help to motivate smoking cessation? A study on the effectiveness of motivational interviewing on engagement and therapeutic alliance. *BMC Public Health*, 22(1), 726. <https://doi.org/10.1186/s12889-022-13115-x>
- [11] Bielawski, K., & Batorski, D. (2022). Sensors and artificial intelligence methods and algorithms for human–computer intelligent interaction: A systematic mapping study. *Sensors*, 22(1), 20. <https://doi.org/10.3390/s22010020>
- [12] Alqahtani, S., & Beloff, N. (2022). User-centric AI: Evaluating the usability of generative AI applications through user reviews on app stores. *PeerJ Computer Science*, 8, e2421. <https://doi.org/10.7717/peerj-cs.2421>
- [13] Jiang, Y., Li, M., & Wang, Q. (2024). Chatbot Usability Scale in Chinese users: Cross-cultural adaptation and validation study. *JMIR Human Factors*, 11, e54971. <https://doi.org/10.2196/54971>
- [14] Gao, Y., & Li, X. (2024). L2 growth mindset in AI-mediated language learning: Effects of perceived usability and presence of generative AI chatbots. *System*, 103456.
- [15] Nasirian, F., Ahmadian, M., & Lee, O. K. (2023). Smart service interactions in hospitality: Factors influencing customer switching intention to chatbots. *Journal of Hospitality and Tourism Management*.
- [16] Roick, T., & Jansen, S. (2023). A motivational interviewing chatbot with generative reflections for increasing readiness to quit smoking: Iterative development study. *JMIR Mental Health*, 10, e49132. <https://doi.org/10.2196/49132>
- [17] Zanker, M., & Jannach, D. (2024). ChatGPT as a conversational recommender system: A user-centric analysis. *User Modeling and User-Adapted Interaction*.