

Guía de redacción de artículo de Revisión Sistemática de Literatura

1. Título

Debe indicar claramente que el estudio es una **revisión sistemática de literatura** y precisar el tema.

Ejemplo:

Machine Learning Techniques for Financial Fraud Detection: A Systematic Literature Review

2. Resumen / Abstract

Resume el artículo en 150–250 palabras. Debe incluir:

- Contexto del problema.
- Objetivo de la revisión.
- Método usado.
- Bases de datos consultadas.
- Número de estudios seleccionados.
- Principales hallazgos.
- Conclusión.

Ejemplo:

Machine Learning Techniques for Financial Fraud Detection: A Systematic Literature Review

Abstract

Financial fraud has become one of the main challenges for financial institutions due to the increasing volume of digital transactions and the sophistication of cybercriminal activities. In recent years, machine learning techniques have emerged as effective approaches for detecting anomalous patterns and preventing fraudulent operations in real time. This systematic literature review analyzes the current state of research on machine learning techniques applied to financial fraud detection. Following the guidelines proposed by Kitchenham and PRISMA, studies indexed in Scopus, IEEE Xplore, ScienceDirect, and ACM Digital Library were systematically searched and evaluated. The review identifies the most frequently used algorithms, the evaluation metrics commonly reported, the financial domains where these models are applied, and the main challenges associated with their implementation. The findings reveal that Random Forest, Support Vector Machines, Decision Trees, and Deep Learning models are among the most widely adopted techniques, with accuracy, precision, recall, F1-score, and AUC being the predominant evaluation metrics. Furthermore, most studies focus on banking and fintech environments, while fewer investigations address insurance and public financial systems. The review also highlights existing limitations related to data imbalance, explainability, privacy concerns, and the scarcity of publicly available datasets. Finally, this study identifies research gaps and future directions for improving intelligent fraud detection systems in financial environments.

Resumen

El fraude financiero se ha convertido en uno de los principales desafíos para las instituciones financieras debido al incremento de las transacciones digitales y la creciente sofisticación de las actividades ciberdelictivas. En los últimos años, las técnicas de machine learning han surgido como enfoques eficaces para detectar patrones anómalos y prevenir operaciones fraudulentas en tiempo real. Esta revisión sistemática de literatura analiza el estado actual de la investigación sobre técnicas de aprendizaje automático

aplicadas a la detección de fraude financiero. Siguiendo las directrices propuestas por Kitchenham y PRISMA, se realizó una búsqueda y evaluación sistemática de estudios indexados en Scopus, IEEE Xplore, ScienceDirect y ACM Digital Library. La revisión identifica los algoritmos más utilizados, las métricas de evaluación más reportadas, los contextos financieros donde se aplican estos modelos y los principales desafíos asociados con su implementación. Los resultados muestran que Random Forest, Support Vector Machines, Árboles de Decisión y modelos de Deep Learning son las técnicas más empleadas, mientras que las métricas predominantes son accuracy, precision, recall, F1-score y AUC. Asimismo, la mayoría de los estudios se concentra en entornos bancarios y fintech, existiendo menos investigaciones orientadas al sector seguros y sistemas financieros públicos. La revisión también evidencia limitaciones relacionadas con el desbalance de datos, la explicabilidad de los modelos, la privacidad y la escasez de conjuntos de datos públicos. Finalmente, este estudio identifica vacíos de investigación y propone futuras líneas de trabajo para mejorar los sistemas inteligentes de detección de fraude en entornos financieros.

3. Palabras clave

Incluye entre 4 y 7 términos.

Ejemplo:

- Systematic Literature Review
- Machine Learning
- Financial Fraud Detection
- Software Engineering
- Digital Transformation

4. Introducción

Explica el problema, la importancia del tema y por qué se necesita una RSL.

Debe responder:

- ¿Cuál es el problema?
- ¿Por qué es relevante?
- ¿Qué se sabe hasta ahora?
- ¿Qué vacío existe?
- ¿Cuál es el objetivo del artículo?

La introducción debe cerrar con las **contribuciones del estudio**.

4.1 Contexto del problema

En la actualidad, el crecimiento acelerado de las transacciones digitales y la expansión de los servicios financieros electrónicos han incrementado significativamente los riesgos asociados al fraude financiero (Cita). Instituciones bancarias, empresas fintech, plataformas de pago electrónico y compañías de seguros enfrentan diariamente amenazas relacionadas con actividades fraudulentas, tales como robo de identidad, transacciones no autorizadas, fraude con tarjetas de crédito y lavado de activos (Cita). Estas amenazas generan pérdidas económicas considerables, afectan la confianza de los usuarios y comprometen la seguridad de los ecosistemas financieros digitales.

Tradicionalmente, los sistemas de detección de fraude se basaban en reglas estáticas y mecanismos manuales de supervisión; sin embargo, estos enfoques presentan limitaciones frente al volumen, velocidad y complejidad de los datos financieros modernos. En este contexto, las técnicas de *Machine Learning* han adquirido relevancia debido a su capacidad para identificar patrones anómalos, aprender comportamientos

históricos y detectar actividades sospechosas en tiempo real mediante modelos predictivos y algoritmos inteligentes.

Diversos estudios han reportado la aplicación de algoritmos como Random Forest, Support Vector Machines (SVM), Árboles de Decisión, Redes Neuronales Artificiales y técnicas de Deep Learning para mejorar la precisión y eficiencia de los sistemas de detección de fraude financiero. No obstante, la literatura científica evidencia una alta diversidad de enfoques, métricas de evaluación, conjuntos de datos y contextos de aplicación, dificultando la comparación objetiva de resultados y la identificación de tendencias consolidadas.

4.2 Problema de investigación

A pesar del creciente interés académico y empresarial en la detección de fraude mediante técnicas de aprendizaje automático, aún existen desafíos relacionados con:

- el desbalance de datos,
- la explicabilidad de los modelos,
- la disponibilidad limitada de datasets públicos,
- la adaptabilidad de los algoritmos frente a nuevos patrones de fraude,
- y la falta de estudios comparativos integrales.

Además, gran parte de las investigaciones se concentran en entornos bancarios y fintech, mientras que otros sectores financieros continúan siendo poco explorados. Esta situación evidencia la necesidad de realizar una revisión sistemática que permita sintetizar el conocimiento actual, identificar tendencias metodológicas y detectar vacíos de investigación.

4.3 Objetivo del estudio

El objetivo de esta revisión sistemática de literatura es analizar las técnicas de *Machine Learning* utilizadas en la detección de fraude financiero, identificando los algoritmos más empleados, las métricas de desempeño reportadas, los contextos de aplicación y las principales limitaciones y desafíos presentes en la literatura científica reciente.

4.4 Preguntas de investigación

Para alcanzar este objetivo, se plantean las siguientes preguntas de investigación:

- **RQ1:** ¿Qué algoritmos de *Machine Learning* se utilizan con mayor frecuencia para la detección de fraude financiero?
- **RQ2:** ¿Qué métricas y niveles de precisión reportan los modelos propuestos en los estudios recientes?
- **RQ3:** ¿En qué contextos financieros (banca, seguros, fintech, pagos digitales) se aplican estos modelos?
- **RQ4:** ¿Cuáles son los principales desafíos y limitaciones reportados en la implementación de modelos de *Machine Learning* para detección de fraude financiero?

4.5 Justificación de la revisión

La presente revisión sistemática contribuye a organizar y sintetizar el conocimiento científico existente sobre técnicas inteligentes de detección de fraude financiero, permitiendo identificar tendencias tecnológicas, algoritmos predominantes y oportunidades de investigación futura. Asimismo, el estudio proporciona una base teórica y metodológica útil para investigadores, desarrolladores y organizaciones financieras

interesadas en implementar soluciones basadas en inteligencia artificial para mejorar la seguridad y confiabilidad de sus sistemas transaccionales. Finalmente, esta investigación busca aportar evidencia científica que facilite la toma de decisiones respecto a la selección de modelos de *Machine Learning* más adecuados según el contexto financiero y las características de los datos disponibles.

5. Antecedentes / Marco teórico

Presenta los conceptos principales necesarios para entender la revisión.

Puede incluir:

- Definiciones clave.
- Modelos previos.
- Tecnologías relacionadas.
- Estudios similares.
- Diferencia entre esta RSL y revisiones anteriores.

5.1 Detección de fraude financiero

El fraude financiero comprende cualquier actividad ilícita orientada a obtener beneficios económicos mediante el engaño, manipulación o uso indebido de información financiera. En entornos digitales, este tipo de fraude se presenta frecuentemente en transacciones bancarias electrónicas, pagos con tarjetas de crédito, plataformas fintech, seguros y sistemas de comercio electrónico. Debido al crecimiento exponencial de las operaciones digitales, las organizaciones financieras enfrentan la necesidad de implementar mecanismos automáticos capaces de detectar actividades fraudulentas de manera rápida y precisa.

Tradicionalmente, los sistemas de detección de fraude se basaban en reglas definidas manualmente por expertos; sin embargo, estos enfoques presentan limitaciones frente a la evolución constante de los patrones de fraude y al gran volumen de datos financieros generados diariamente. En consecuencia, las técnicas de inteligencia artificial y aprendizaje automático han surgido como alternativas más eficientes para identificar anomalías y patrones sospechosos en tiempo real.

5.2 Machine Learning aplicado a la detección de fraude

El *Machine Learning* es una rama de la inteligencia artificial que permite a los sistemas aprender automáticamente a partir de datos históricos para realizar predicciones o clasificaciones sin necesidad de ser programados explícitamente. En el contexto de detección de fraude financiero, los algoritmos de aprendizaje automático analizan grandes volúmenes de transacciones para identificar comportamientos anómalos asociados a actividades fraudulentas.

Los modelos de *Machine Learning* utilizados en este dominio suelen clasificarse en:

Tipo de aprendizaje	Características	Ejemplo
Supervisado	Utiliza datos etiquetados	Random Forest, SVM
No supervisado	Detecta anomalías sin etiquetas	K-Means, Isolation Forest
Deep Learning	Redes neuronales profundas	CNN, LSTM, Autoencoders

El aprendizaje supervisado es el enfoque más utilizado debido a la disponibilidad de datasets históricos etiquetados con transacciones legítimas y fraudulentas.

5.3 Algoritmos más utilizados

La literatura científica reporta diversos algoritmos aplicados a la detección de fraude financiero. Entre los más utilizados destacan:

Random Forest

Modelo basado en múltiples árboles de decisión que mejora la precisión y reduce el sobreajuste. Es ampliamente utilizado debido a su robustez y capacidad de clasificación.

Support Vector Machines (SVM)

Algoritmo de clasificación que busca separar las clases mediante hiperplanos óptimos. Es efectivo en datasets de alta dimensionalidad.

Árboles de Decisión

Método interpretable y fácil de implementar para clasificación de transacciones financieras.

Redes Neuronales Artificiales

Modelos inspirados en el funcionamiento del cerebro humano capaces de identificar patrones complejos.

Deep Learning

Técnicas avanzadas como LSTM y Autoencoders permiten detectar patrones sofisticados en grandes volúmenes de datos financieros.

5.4 Métricas de evaluación

Los estudios sobre detección de fraude financiero emplean diversas métricas para medir el desempeño de los modelos predictivos. Las más frecuentes son:

Métrica	Descripción
Accuracy	Proporción de predicciones correctas
Precision	Capacidad de identificar correctamente fraudes
Recall	Capacidad de detectar todos los fraudes
F1-score	Balance entre precisión y recall
AUC-ROC	Capacidad discriminativa del modelo

Debido al desbalance de clases presente en datasets financieros, métricas como *precision*, *recall* y F1-score suelen ser más relevantes que el accuracy.

5.5 Tecnologías relacionadas

La detección de fraude financiero mediante *Machine Learning* involucra diversas tecnologías y herramientas utilizadas durante el procesamiento, entrenamiento y evaluación de modelos.

Frameworks y librerías

- Scikit-learn
- TensorFlow
- Keras
- PyTorch
- XGBoost

Herramientas de análisis de datos

- Python
- R
- Jupyter Notebook
- Apache Spark

Bases de datos y plataformas

- Kaggle datasets

- IEEE DataPort
- UCI Machine Learning Repository

Estas tecnologías permiten desarrollar modelos escalables y automatizados para el análisis de grandes volúmenes de transacciones financieras.

5.6 Estudios previos relacionados

Diversos estudios han investigado la aplicación de *Machine Learning* en la detección de fraude financiero. La mayoría de las investigaciones se enfoca en el sector bancario y tarjetas de crédito, reportando altos niveles de precisión mediante algoritmos supervisados.

Algunos estudios comparan múltiples algoritmos para identificar el modelo con mejor rendimiento, mientras que otros proponen arquitecturas híbridas basadas en Deep Learning y técnicas de detección de anomalías. Asimismo, investigaciones recientes han explorado el uso de inteligencia artificial explicable (*Explainable AI*) para mejorar la interpretabilidad de los modelos y aumentar la confianza de las organizaciones financieras.

No obstante, muchos trabajos presentan limitaciones relacionadas con:

- datasets privados no accesibles,
- desbalance de datos,
- falta de validación en escenarios reales,
- y ausencia de comparaciones homogéneas entre modelos.

5.7 Diferencia entre esta RSL y revisiones anteriores

Aunque existen revisiones previas relacionadas con la detección de fraude financiero, muchas de ellas:

- se enfocan únicamente en algoritmos específicos,
- analizan periodos temporales limitados,
- o no consideran conjuntamente métricas, contextos de aplicación y limitaciones metodológicas.

La presente revisión sistemática se diferencia porque:

- analiza múltiples algoritmos de *Machine Learning* y *Deep Learning*;
- compara métricas de desempeño reportadas;
- identifica los sectores financieros más estudiados;
- examina desafíos y vacíos de investigación;
- y sintetiza evidencia reciente proveniente de bases de datos indexadas como Scopus, IEEE y ACM.

Además, esta RSL busca proporcionar una visión integral y actualizada del estado del arte, contribuyendo tanto a la investigación académica como al desarrollo de futuras soluciones inteligentes para la detección de fraude financiero.

6. Método de revisión

Es una de las secciones más importantes. Debe explicar exactamente cómo se hizo la RSL.

Se recomienda seguir guías como **Kitchenham, PRISMA** o SEGRESS para Ingeniería de Software (Kitchenham et al., 2023).

Debe incluir:

a. Preguntas de investigación

Son las RQs que guían toda la revisión.

Ejemplo:

RQ1: ¿Qué algoritmos se usan para detectar fraude financiero?

RQ2: ¿Qué métricas reportan los estudios?

RQ3: ¿Qué vacíos existen en la literatura?

b. Protocolo de revisión

Describe el plan previo de la revisión: (Fintech OR Financial) AND (“Machine learning” OR “Random Forest”) AND (Accuracy OR Precision OR Recall)

- Objetivo.
- Fuentes.
- Cadenas de búsqueda.
- Criterios.
- Procedimiento de selección.
- Método de análisis.

c. Fuentes de datos

Indica las bases consultadas:

- Scopus
- Web of Science
- IEEE Xplore
- ACM Digital Library
- ScienceDirect
- SpringerLink

d. Estrategia de búsqueda

Incluye la cadena usada.

Ejemplo:

("financial fraud" OR "fraud detection")

AND

("machine learning" OR "deep learning")

AND

("classification" OR "prediction")

e. Criterios de inclusión y exclusión

Define qué estudios entran y cuáles se eliminan.

Inclusión:

- Artículos revisados por pares.
- Estudios entre 2020–2025.
- Estudios con resultados empíricos.
- Texto completo disponible.

Exclusión:

- Duplicados.
- Artículos sin metodología.
- Estudios no relacionados.
- Resúmenes sin texto completo.

f. Proceso de selección

Explica cómo se filtraron los artículos.

Ejemplo:

- 250 artículos encontrados.

- 180 después de eliminar duplicados.
- 75 tras revisar título y resumen.
- 32 incluidos tras leer texto completo.

Puede representarse con un diagrama PRISMA.

g. Evaluación de calidad

Describe cómo se evaluó la calidad de los estudios.

Ejemplo de criterios:

- ¿El objetivo es claro?
- ¿La metodología está bien descrita?
- ¿Los datos son suficientes?
- ¿Los resultados responden a la pregunta?
- ¿Se reportan limitaciones?

h. Extracción de datos

Explica qué información se obtuvo de cada estudio.

Ejemplo:

- Autor.
- Año.
- País.
- Método.
- Algoritmo.
- Dataset.
- Métricas.
- Resultados.
- Limitaciones.

7. Resultados

Presenta los hallazgos de forma objetiva.

Puede incluir:

- Número de estudios por año.
- Revistas o conferencias más frecuentes.
- Países más estudiados.
- Métodos más usados.
- Tecnologías más aplicadas.
- Métricas reportadas.

Aquí se usan tablas, gráficos y frecuencias.

En esta sección se presentan los hallazgos obtenidos después de aplicar el protocolo de revisión sistemática. Los resultados se describen de manera objetiva, usando frecuencias, porcentajes, tablas y gráficos que permiten identificar tendencias en la literatura sobre técnicas de *Machine Learning* para la detección de fraude financiero.

7.1 Distribución de estudios por año

La revisión permitió identificar una tendencia creciente en la publicación de estudios sobre detección de fraude financiero mediante *Machine Learning*, especialmente en los últimos años, debido al incremento de transacciones digitales y al interés por modelos inteligentes de seguridad financiera.

Año	Número de estudios	Porcentaje
2020	4	13.3%
2021	5	16.7%
2022	6	20.0%
2023	7	23.3%
2024	8	26.7%
Total	30	100%

Interpretación: Se observa un aumento progresivo de publicaciones, lo que evidencia que la detección de fraude financiero con *Machine Learning* es un campo de investigación vigente y en expansión.

7.2 Fuentes de publicación más frecuentes

Los estudios revisados se publicaron principalmente en revistas y conferencias relacionadas con inteligencia artificial, ciencia de datos, seguridad informática e ingeniería de software.

Fuente	Tipo	Frecuencia
IEEE Access	Revista	6
Expert Systems with Applications	Revista	5
Applied Sciences	Revista	4
Journal of Financial Crime	Revista	3
ACM International Conference Proceedings	Conferencia	3
Procedia Computer Science	Conferencia/Revista	3
Otras fuentes	Revista/Conferencia	6

Interpretación: Las revistas indexadas y conferencias de IEEE y ACM concentran una proporción importante de investigaciones, lo cual refleja el enfoque tecnológico del tema.

7.3 Países más estudiados

Los estudios analizados muestran mayor concentración en países con alto desarrollo financiero y tecnológico.

País / Región	Frecuencia
Estados Unidos	7
China	5
India	5
Reino Unido	3
Brasil	2
España	2
Otros países	6

Interpretación: Existe una mayor producción científica en países con ecosistemas financieros digitales consolidados. Sin embargo, se identifica una limitada presencia de estudios en América Latina, lo que representa una oportunidad para futuras investigaciones.

7.4 Métodos de investigación más usados

Los métodos más frecuentes en los artículos revisados fueron los estudios experimentales y comparativos, en los cuales se entrenan y evalúan distintos algoritmos sobre conjuntos de datos financieros.

Método de investigación	Frecuencia	Descripción
Experimental	14	Entrenamiento y prueba de modelos con datasets
Comparativo	8	Comparación entre algoritmos
Estudio de caso	4	Aplicación en una entidad o contexto específico
Revisión / análisis secundario	3	Síntesis de literatura previa
Propuesta de arquitectura	1	Diseño de solución tecnológica

Interpretación: Predominan los estudios experimentales, lo cual indica que la literatura se orienta principalmente a evaluar el rendimiento técnico de modelos predictivos.

7.5 Algoritmos y tecnologías más aplicadas

Los algoritmos más utilizados corresponden a modelos supervisados de clasificación, aunque también se identifican enfoques de *Deep Learning* y detección de anomalías.

Técnica / Algoritmo	Frecuencia
Random Forest	12
Support Vector Machine	10
Decision Tree	8
Logistic Regression	7
Artificial Neural Networks	7
XGBoost	6
Convolutional Neural Networks	4
Autoencoders	3
Isolation Forest	3

Interpretación: Random Forest y SVM aparecen como los algoritmos más recurrentes, debido a su buen desempeño en tareas de clasificación y detección de patrones fraudulentos.

7.6 Tecnologías y herramientas reportadas

Los estudios revisados emplean principalmente herramientas de análisis de datos y aprendizaje automático.

Tecnología / Herramienta	Uso principal
Python	Procesamiento y modelado
Scikit-learn	Modelos clásicos de Machine Learning
TensorFlow / Keras	Modelos de Deep Learning
PyTorch	Redes neuronales avanzadas
R	Análisis estadístico
Apache Spark	Procesamiento de grandes volúmenes de datos
Jupyter Notebook	Experimentación y visualización

Interpretación: Python es la tecnología predominante debido a su ecosistema de librerías para ciencia de datos y aprendizaje automático.

7.7 Métricas de evaluación reportadas

Los artículos revisados utilizaron diversas métricas para evaluar el desempeño de los modelos. Debido al desbalance de clases en los datos de fraude, las métricas más relevantes fueron *precision*, *recall*, F1-score y AUC.

Métrica	Frecuencia	Uso
Accuracy	20	Medición general de aciertos
Precision	18	Exactitud en la detección de fraudes
Recall	17	Capacidad para detectar casos fraudulentos
F1-score	16	Balance entre precision y recall
AUC-ROC	12	Capacidad discriminativa del modelo
Matriz de confusión	10	Análisis de verdaderos/falsos positivos

Interpretación: Aunque *accuracy* es una métrica ampliamente reportada, no siempre es suficiente en problemas de fraude financiero, debido al fuerte desbalance entre transacciones legítimas y fraudulentas.

7.8 Síntesis objetiva de hallazgos

Los resultados muestran que la investigación sobre detección de fraude financiero mediante *Machine Learning* se concentra principalmente en estudios experimentales, con fuerte presencia de algoritmos supervisados como Random Forest, SVM y Árboles de Decisión. Asimismo, las métricas más reportadas son *accuracy*, *precision*, *recall*, F1-score y AUC. Se evidencia una tendencia creciente en publicaciones recientes, aunque persisten vacíos relacionados con la baja disponibilidad de datasets públicos, la limitada representación de estudios latinoamericanos y la necesidad de modelos más explicables y aplicables en entornos reales.

8. Síntesis de resultados

No solo presenta datos, sino que los interpreta por pregunta de investigación.

Ejemplo:

Para RQ1, los estudios muestran que Random Forest, SVM y redes neuronales son los algoritmos más usados en detección de fraude.

Para RQ2, las métricas más frecuentes son accuracy, precision, recall, F1-score y AUC.

9. Discusión

Analiza el significado de los resultados.

Debe explicar:

- Qué patrones aparecen.
- Qué hallazgos son consistentes.
- Qué resultados son contradictorios.
- Qué aportan los estudios revisados.
- Qué implicancias tienen para la teoría y la práctica.

10. Vacíos de investigación

Identifica lo que aún falta estudiar.

Ejemplo:

- Pocos estudios en América Latina.

- Falta de datasets abiertos.
- Escasa validación en entornos reales.
- Poca comparación entre modelos.

Esta sección es clave para justificar una tesis o nuevo artículo.

11. Amenazas a la validez / Limitaciones

Reconoce posibles debilidades de la RSL.

Puede incluir:

- Sesgo por selección de bases.
- Sesgo de idioma.
- Restricción temporal.
- Dificultad para acceder a textos completos.
- Subjetividad en la selección de artículos.

12. Conclusiones

Resume los principales aportes de la revisión.

Debe responder:

- ¿Qué se encontró?
- ¿Qué se aprendió?
- ¿Qué vacío queda?
- ¿Qué futuras investigaciones se recomiendan?

13. Referencias

Incluye todas las fuentes citadas, preferentemente:

- Artículos indexados.
- Estudios recientes.
- Fuentes con DOI.
- Normas de la revista.

Estructura recomendada final

Título

Resumen

Palabras clave

1. Introducción

2. Antecedentes

3. Método de revisión

4. Resultados

5. Síntesis y discusión

6. Vacíos de investigación

7. Amenazas a la validez

8. Conclusiones

Referencias

En revistas Scopus Q1/Q2, la sección más observada será el **método de revisión**, porque allí se demuestra si la RSL es realmente **sistemática**, transparente y replicable (García-Holgado et al., 2022), (Kuhrmann et al., 2017).

Referencias bibliográficas

- García-Holgado, A., Marcos-Pablos, S., & García-Peñalvo, F. (2022). *Guidelines for performing Systematic Research Projects Reviews*.
<https://doi.org/10.9781/ijimai.2020.05.005>
- Kitchenham, B., Madeyski, L., & Budgen, D. (2023). SEGRESS: Software Engineering Guidelines for REporting Secondary Studies. *IEEE Transactions on Software Engineering*, 49(3), 1273-1298. <https://doi.org/10.1109/TSE.2022.3174092>
- Kuhrmann, M., Fernández, D. M., & Daneva, M. (2017). On the pragmatic design of literature studies in software engineering: An experience-based guideline. *Empirical Software Engineering*, 22(6), 2852-2891.
<https://doi.org/10.1007/s10664-016-9492-y>