

Evaluación de la Experiencia de Usuario en Agentes Conversacionales Impulsados por IA: Una Revisión Sistemática de Literatura

Kenny Danny Martínez Fuentes¹,

Christian Angelo Guerrero Falla¹, Jose Luis Vergara Pachas¹,
JeanPierre D'Angelo Motta Chumbe¹, Felipe Triveño Daza¹, Jose Sernaque Gutiérrez¹ ¹ Facultad de

Ingeniería de Sistemas e Informática
Universidad Nacional Mayor de San Marcos
Lima, Perú

Resumen: La adopción masiva de agentes conversacionales impulsados por inteligencia artificial ha transformado la interacción humano-computadora en dominios como la salud, la educación y el servicio al cliente. Sin embargo, la evaluación de la Experiencia de Usuario (UX) en estos sistemas exhibe una notable fragmentación metodológica. Esta revisión sistemática de literatura analiza y sintetiza el estado del arte respecto a las metodologías, instrumentos y métricas utilizados para evaluar la UX en agentes conversacionales e interfaces adaptativas impulsadas por IA. Se siguió el protocolo PRISMA para la búsqueda y selección de estudios en las bases de datos Scopus, IEEE Xplore, Springer, MDPI, BMC y JMIR, aplicando criterios de inclusión y exclusión para el periodo 2021–2026. La búsqueda inicial arrojó 347 resultados, de los cuales 17 estudios cumplieron con todos los criterios de selección. Los hallazgos revelan una transición progresiva desde escalas genéricas de usabilidad hacia instrumentos nativos como el Chatbot Usability Scale (BUS), y la identificación de tres capas consistentes de juicio del usuario: pragmática, socio-afectiva y de rendición de cuentas. La revisión concluye que la evaluación UX en interfaces conversacionales requiere instrumentos multidimensionales que trasciendan la usabilidad pragmática, e identifica vacíos críticos en evaluación longitudinal, adaptabilidad demográfica y explicabilidad ética como direcciones prioritarias para futuras investigaciones. **Palabras clave:** Agentes conversacionales; Experiencia de Usuario; Evaluación de usabilidad; Chatbot

Usability Scale; Interfaces adaptativas; Inteligencia artificial; Revisión sistemática. **Abstract:** The massive adoption of conversational agents powered by artificial intelligence has transformed human-computer interaction. This systematic literature review analyzes methodologies, instruments, and metrics used to evaluate UX in conversational agents and adaptive interfaces powered by AI. The PRISMA protocol was followed, searching Scopus, IEEE Xplore, Springer, MDPI, BMC, and JMIR for 2021–2026. Of 347 initial results, 17 studies met all criteria. Findings reveal a transition from generic usability scales to native instruments like the Chatbot Usability Scale (BUS), and the identification of three consistent layers of user judgment: pragmatic, socio-affective, and accountability. The review concludes that UX evaluation in conversational interfaces requires multidimensional instruments that transcend pragmatic usability, and identifies critical gaps in longitudinal evaluation, demographic adaptability, and ethical explainability as priority directions for future research. **Keywords:** Conversational agents; User Experience; Usability evaluation; Chatbot Usability Scale; Adaptive interfaces; Artificial intelligence; Systematic review.

1. Introducción

En los últimos años, la adopción ubicua de agentes conversacionales impulsados por inteligencia artificial (IA) ha transformado sustancialmente la interacción humano-

computadora [1]. Diversas investigaciones empíricas indican que estos sistemas se han integrado de manera progresiva en dominios críticos como la educación [2, 3], la atención médica [10, 13, 14] y el servicio al cliente [8]. La capacidad de las máquinas para simular diálogos intuitivos

tivos ha modificado el panorama del diseño, desplazando el enfoque desde las interfaces gráficas unidimensionales hacia entornos predominantemente conversacionales. Los chatbots virtuales asistentes, en particular, representan un caso de estudio paradigmático dentro de este nuevo paradigma de interacción [1], dado que combinan componentes de procesamiento de lenguaje natural, generación de respuestas y gestión de estados de diálogo en una única interfaz conversacional.

Frente a esta adopción masiva, el estado del arte sugiere la reconceptualización de la calidad de la interacción como un constructo de alta complejidad multidimensional [4]. A diferencia del software tradicional centrado exclusivamente en la usabilidad pragmática, la experiencia del usuario frente a la IA involucra respuestas relacionales, cognitivas y afectivas que se co-construyen en tiempo real [5]. Los elementos subyacentes del diseño operan frecuentemente como señales sociales críticas que moldean directamente la percepción humana [6]. Esta reconceptualización tiene implicaciones directas para las metodologías de evaluación, ya que las escalas tradicionales de usabilidad fueron diseñadas para interfaces estáticas y no capturan la naturaleza dinámica y adaptativa de los sistemas conversacionales.

Sin embargo, la evidencia empírica respecto a la evaluación UX exhibe una notable fragmentación metodológica [1]. La literatura indica que el campo carece de marcos unificados que integren el rendimiento algorítmico con las dimensiones holísticas percibidas por el ser humano [4]. Esta fragmentación se manifiesta en la coexistencia de instrumentos genéricos como el System Usability Scale (SUS), instrumentos nativos específicamente diseñados para chatbots como el Chatbot Usability Scale (BUS), y escalas ad-hoc que dificultan la comparabilidad entre estudios. La ausencia de un marco evaluativo unificado representa un obstáculo significativo tanto para la investigación académica como para el desarrollo industrial de sistemas conversacionales.

1.1 Problema de investigación

A pesar de la rápida adopción de agentes conversacionales, la evaluación de la UX presenta vacíos concurrentes: (i) carencia de instrumentos nativos e integrales [5, 9]; (ii) limitaciones algorítmicas frente a la complejidad del con-

texto [1]; (iii) dificultad en la consolidación de vínculos de confianza a largo plazo [10]; (iv) opacidad ética y falta de explicabilidad [8]; y (v) inconsistencia en la adaptabilidad demográfica [6].

1.2 Objetivo

El objetivo principal de esta revisión sistemática es analizar y sintetizar el estado del arte respecto a las metodologías, instrumentos y métricas utilizados para evaluar la UX en sistemas interactivos modernos, con énfasis en agentes conversacionales impulsados por IA.

1.3 Preguntas de investigación

- **RQ1:** ¿Qué escalas de medición se utilizan con mayor frecuencia para evaluar la UX en agentes conversacionales?
- **RQ2:** ¿Qué métricas se emplean para articular el rendimiento técnico con las dimensiones cognitivas y socio-afectivas del usuario?
- **RQ3:** ¿Cómo aborda la literatura actual la evaluación de aspectos como la explicabilidad ética y la adaptabilidad demográfica?
- **RQ4:** ¿Cuáles son las principales limitaciones metodológicas y vacíos de diseño reportados?

1.4 Justificación de la revisión

La presente revisión sistemática contribuye a organizar y sintetizar el conocimiento empírico existente sobre la evaluación UX en agentes conversacionales, permitiendo identificar tendencias tecnológicas, instrumentos predominantes y oportunidades de investigación futura. Esta investigación resulta de particular relevancia para investigadores en interacción humano-computadora, ingenieros de software y diseñadores de interfaces interesados en desarrollar evaluaciones empíricas verdaderamente integrales. Asimismo, proporciona una base teórica y metodológica que facilita la selección de instrumentos de evaluación adecuados según el dominio de aplicación y las características de los usuarios, contribuyendo tanto a la investigación académica como al desarrollo de futuras soluciones inteligentes centradas en el usuario.

2. Antecedentes

2.1 Agentes conversacionales e interfaces adaptativas

Los agentes conversacionales son sistemas interactivos impulsados por IA que simulan diálogos intuitivos para asistir a los usuarios [1]. Estos sistemas combinan arquitecturas algorítmicas con interfaces de lenguaje natural [3]. Las interfaces adaptativas incorporan mecanismos capaces de captar información del comportamiento y del estado cognitivo del usuario para ajustar la interacción en tiempo real [7]. Desde una perspectiva histórica, los sistemas conversacionales han evolucionado desde chatbots basados en reglas hasta sistemas modernos basados en modelos de lenguaje de gran escala (LLM), lo que ha generado nuevas demandas en materia de evaluación de la experiencia del usuario.

La arquitectura típica de un agente conversacional moderno incluye componentes de procesamiento de lenguaje natural (NLU), gestión del diálogo (DM) y generación de respuestas (NLG). Cada uno de estos componentes influye en la percepción del usuario de maneras distintas: la comprensión del lenguaje natural afecta la precisión de la interacción, la gestión del diálogo determina la coherencia conversacional, y la generación de respuestas impacta la naturalidad y satisfacción percibida [1]. Esta complejidad arquitectónica hace que la evaluación UX sea intrínsecamente multidimensional, requiriendo instrumentos que capturen no solo la eficiencia funcional, sino también dimensiones socio-afectivas y éticas.

2.2 Experiencia del Usuario multidimensional en IA

A diferencia del software tradicional, la interacción con IA redefine la calidad como un constructo multidimensional [4]. La UX abarca no solo la eficiencia técnica, sino que involucra respuestas relacionales, cognitivas y afectivas [5]. Se han identificado tres capas de juicio del usuario: un núcleo pragmático, una capa socio-afectiva y una capa de rendición de cuentas [4]. El núcleo pragmático se refiere a la utilidad percibida, la eficiencia y la facilidad de uso del sistema. La capa socio-afectiva incluye dimensiones como la empatía percibida, la presencia social y la confianza interpersonal. La capa de rendición de cuentas abarca la explicabilidad, la transparencia y la responsabilidad ética del sistema.

Esta estructura tripartita ha sido validada empíricamente en múltiples dominios [4], y sugiere que las escalas de evaluación deben ser capaces de capturar diferencias sutiles entre estas capas. Por ejemplo, un chatbot puede obtener puntuaciones altas en eficiencia pragmática pero bajas en explicabilidad ética, lo que tendría implicaciones significativas para su adopción en dominios sensibles como la salud o la educación.

2.3 Evolución de las métricas

Históricamente, la evaluación de software se apoyó en instrumentos genéricos como el SUS [18]. Sin embargo, estos instrumentos fracasan al capturar las propiedades dinámicas del diálogo mediado por IA [5]. En respuesta, se desarrolló el BUS-15, optimizado a BUS-11 con propiedades psicométricas robustas [9]. La evolución del SUS al BUS-15 y posteriormente al BUS-11 representa un caso paradigmático de adaptación de instrumentos de evaluación a nuevas tecnologías. Mientras que el SUS fue diseñado para interfaces gráficas de usuario (GUI) con tareas predefinidas, los instrumentos nativos para chatbots deben considerar variables adicionales como la latencia de respuesta, la coherencia del diálogo y la personalidad del agente.

El BUS-15, desarrollado por Borsci et al. [5], consta de 15 ítems organizados en cinco dimensiones: general, aspectos conversacionales, aspectos visuales, aspectos de personalización y aspectos técnicos. Posteriormente, el BUS-11 [9] optimizó esta escala a 11 ítems, manteniendo propiedades psicométricas robustas y añadiendo validación multilingüe en cuatro idiomas (inglés, español, alemán y chino). Esta evolución refleja la necesidad de instrumentos más eficientes sin sacrificar la validez ni la confiabilidad de las mediciones.

2.4 Evaluación en dominios críticos

En sistemas de recomendación, la evaluación ha dependido de métricas matemáticas de precisión [8]. En educación, chatbots como tutores virtuales han demostrado mejoras en el aprendizaje [2, 3]. En salud, la alianza terapéutica y la empatía del agente son dimensiones críticas [10, 13, 14]. Cada dominio presenta requisitos específicos de evaluación que reflejan las particularidades del contexto de uso. En el ámbito de la salud, por ejemplo, la

confidencialidad de los datos, la precisión de la información y la responsabilidad ética adquieren una relevancia que no necesariamente está presente en dominios menos sensibles como el entretenimiento.

Los sistemas de recomendación conversacionales representan un caso particularmente interesante, ya que deben equilibrar la precisión algorítmica con la satisfacción subjetiva del usuario [8]. Jannach (2022) identifica una brecha teórica persistente donde los modelos de caja negra son optimizados por métricas estadísticas cerradas que no necesariamente se correlacionan con la experiencia del usuario. Esta desconexión entre métricas algorítmicas y percepción humana constituye uno de los desafíos más significativos en la evaluación de sistemas de recomendación conversacionales.

3. Método de revisión

Se siguieron las directrices PRISMA [19] y SEGRESS [20] para garantizar la transparencia y replicabilidad de la revisión. El protocolo de revisión fue diseñado para abordar de manera sistemática las preguntas de investigación formuladas, garantizando la reproducibilidad de los procedimientos de búsqueda, selección y extracción de datos.

3.1 Protocolo de revisión

El protocolo incluyó: (i) delimitación del alcance mediante el marco PICOC (Población, Intervención, Comparación, Resultado, Contexto); (ii) definición de preguntas de investigación; (iii) establecimiento de criterios de inclusión y exclusión; y (iv) procedimiento de selección y extracción de datos. El marco PICOC permitió delimitar el alcance de la revisión de manera precisa: Población (usuarios de agentes conversacionales), Intervención (instrumentos y métodos de evaluación UX), Comparación (entre diferentes instrumentos y dominios), Resultado (métricas de UX y hallazgos), y Contexto (sistemas conversacionales impulsados por IA en el periodo 2021–2026).

3.2 Fuentes de datos

Se consultaron seis bases de datos indexadas (Tabla 1):

Tabla 1: Bases de datos consultadas.

Base	Cobertura	Nº
Scopus	Multidisciplinaria	124
IEEE Xplore	Ingeniería	67
SpringerLink	Multidisciplinaria	89
MDPI	Ciencias abiertas	38
BMC	Salud	21
JMIR	Salud digital	8
Total		347

3.3 Cadena de búsqueda

Se aplicaron cadenas de búsqueda con operadores booleanos:

("conversational agent" OR "chatbot") AND
 ("user experience" OR "usability") AND
 ("evaluation" OR "assessment" OR "scale")

3.4 Criterios de selección

Tabla 2: Criterios de selección de estudios.

Inclusión	Exclusión
Revisión por pares	Sin revisión por pares
2021–2026	Anteriores a 2021
Evaluación empírica	Sin componente empírico
Texto completo	Solo resúmenes
Inglés o español	Otros idiomas

3.5 Proceso de selección

La Figura 1 presenta el diagrama PRISMA:




Figura 1: Diagrama de flujo PRISMA 2020.

4. Resultados

4.1 Distribución por año

Tabla 3: Distribución por año de publicación.

Año	Nº	%
2021	4	23.5
2022	6	35.3
2023	3	17.6
2024	2	11.8
2025	1	5.9
2026	1	5.9
Total	17	100

4.2 Distribución por dominio

Tabla 4: Estudios por dominio de aplicación.

Dominio	Nº	%
Salud y bienestar	7	41.2
Educación y aprendizaje	2	11.8
Sistemas de recomendación	1	5.9
General / Frameworks	7	41.2
Total	17	100

4.3 Instrumentos de evaluación

Tabla 5: Instrumentos de evaluación UX.

Instrumento	Tipo	Frec.
SUS	Genérica	3
BUS-15	Nativa	1
BUS-11	Nativa	1
CHISM	Nativa	1
BOT-Check	Nativa	1
UMUX-LITE	Genérica	1
Framework CALO	Nativa	1
Likert ad-hoc	Ad-hoc	6

3.6 Evaluación de calidad

Los estudios incluidos fueron evaluados siguiendo criterios de calidad adaptados de la guía SEGRESS [20]. Los criterios aplicados fueron: (i) claridad en la formulación del objetivo de investigación; (ii) descripción adecuada de la metodología de evaluación; (iii) suficiencia del tamaño de muestra; (iv) uso de instrumentos de medición validados o justificados; (v) presentación de resultados cuantitativos y/o cualitativos; y (vi) reporte de limitaciones. Solo se incluyeron estudios que cumplieron con al menos cuatro de estos seis criterios, garantizando así la fiabilidad académica de la evidencia extraída.

3.7 Extracción de datos

La selección y extracción de datos fueron realizadas por dos revisores independientes. Se extrajeron: autor(es), año, país, dominio, método de evaluación, instrumento, métricas, tamaño de muestra, hallazgos y limitaciones.

4.4 Métricas reportadas

Tabla 6: Métricas de evaluación frecuentes.

Métrica	Frec.
Satisfacción del usuario	14
Usabilidad percibida	12
Calidad de la conversación	8
Intención de reuso	7
Presencia social	6
Tasa de finalización	5
Empatía percibida	4
Confianza percibida	4
Explicabilidad	3
Tiempo de respuesta	3

4.5 Resumen de estudios

La Tabla 8 resume los 17 estudios incluidos. Los nombres de autores se presentan como texto descriptivo para facilitar la lectura; la referencia completa se encuentra en la sección de Bibliografía. La tabla completa se presenta en el Apéndice A.

5. Síntesis y discusión

5.1 RQ1: Escalas de medición predominantes

La revisión evidencia una transición progresiva desde escalas genéricas hacia instrumentos nativos. El sistema SUS sigue siendo utilizado en 3 de los 17 estudios, pero múltiples autores [5, 4] señalan que resulta insuficiente para capturar las particularidades del diálogo mediado por IA. El BUS-15 y su versión optimizada BUS-11 [9] emergen como los instrumentos nativos más consolidados, con validación multilingüe en cuatro idiomas. El CHISM [3] representa un avance en la evaluación de chatbots educativos. Sin embargo, 6 de los 17 estudios utilizan escalas ad-hoc, lo que dificulta la comparabilidad.

Esta fragmentación instrumentológica tiene implicaciones directas para la acumulación de conocimiento en el campo. Cuando cada estudio utiliza instrumentos diferentes, la síntesis de evidencia se vuelve extremadamente difícil, lo que perpetúa la dispersión metodológica identificada en la literatura [1]. La adopción de instrumentos nativos estandarizados como el BUS-11 podría facilitar la

comparabilidad entre estudios y acelerar la construcción de un cuerpo de conocimiento acumulativo.

5.2 RQ2: Articulación técnico-perceptiva

Los hallazgos revelan que la latencia algorítmica opera como una señal social crítica [6]. El estudio de Wang y Lo (2025) [6] demuestra que los adultos mayores prefieren sistemas con retrasos controlados que simulan la reflexión humana, mientras que los adultos jóvenes priorizan la inmediatez. Jannach (2022) [8] identifica una brecha teórica persistente donde los modelos de caja negra son optimizados por métricas estadísticas cerradas. Marconi et al. (2026) [4] formalizan esta dualidad en un marco de cuatro capas: Capacity, Alignment, Levers y Outcomes.

Esta desconexión entre métricas algorítmicas y percepción humana tiene consecuencias prácticas significativas para el diseño de sistemas conversacionales. Los ingenieros de software que optimizan exclusivamente métricas técnicas como la precisión de la comprensión del lenguaje natural o la velocidad de respuesta podrían estar generando sistemas que son técnicamente eficientes pero que no necesariamente proporcionan una experiencia satisfactoria para el usuario. La incorporación de métricas de UX en el ciclo de desarrollo es, por lo tanto, un componente esencial para la construcción de sistemas conversacionales exitosos.

5.3 RQ3: Explicabilidad ética y adaptabilidad demográfica

Solo 3 de los 17 estudios abordan explícitamente la transparencia algorítmica [8, 4, 11]. Wang y Lo (2025) [6] demuestran diferencias significativas generacionales, y Borsci et al. (2022) [9] reportan que los participantes de mayor edad califican los chatbots como menos satisfactorios.

La Tabla 7 sintetiza los aspectos de explicabilidad y adaptabilidad abordados en la literatura revisada.

Tabla 7: Aspectos de explicabilidad y adaptabilidad demográfica.

Aspecto	Estudios
Transparencia algorítmica	Jannach (2022), Marconi et al. (2026)
Responsabilidad ética	Marconi et al. (2026)
Sesgo algorítmico	Bielawski (2022)
Diferencias por edad	Wang y Lo (2025), Borsci et al. (2022)
Diferencias por cultura	Følstad et al. (2021)

La escasez de estudios sobre explicabilidad ética es particularmente preocupante considerando el contexto regulatorio actual. Directrices como el Reglamento General de Protección de Datos (GDPR) de la Unión Europea establecen el derecho a la explicabilidad de las decisiones automatizadas, lo que tiene implicaciones directas para los sistemas conversacionales basados en IA. La incorporación de mecanismos de explicabilidad en el diseño de chatbots no es solo una cuestión ética, sino también una necesidad legal en muchos contextos regulatorios.

Las diferencias demográficas identificadas en la literatura sugieren que los instrumentos de evaluación deben ser sensibles a las características culturales y etarias de los usuarios. Un chatbot que es percibido como satisfactorio por usuarios jóvenes podría ser percibido como inadecuado por usuarios mayores, lo que tiene implicaciones para la personalización de la experiencia y el diseño inclusivo. Sin embargo, ningún instrumento nativo actualmente incorpora ítems específicos para evaluar la adaptabilidad demográfica, lo que representa un vacío significativo en el estado del arte.

5.4 RQ4: Limitaciones metodológicas

Las principales limitaciones son: (i) dependencia de encuestas retrospectivas [4]; (ii) sobre-representación de demografías occidentales [1]; (iii) escasez de validaciones longitudinales [2]; y (iv) desconexión entre métricas algorítmicas y UX [8].

La dependencia de encuestas retrospectivas representa una limitación significativa, ya que los usuarios tienden a recordar su experiencia de manera selectiva, lo que puede introducir sesgos en las mediciones. La evaluación en

tiempo real, a través de métodos como la telemetría del diálogo o la captura de señales fisiológicas, podría proporcionar una imagen más precisa de la experiencia del usuario durante la interacción.

La sobre-representación de demografías occidentales limita la generalización de los hallazgos a contextos culturales diferentes. La validación de instrumentos en poblaciones diversas es esencial para garantizar la aplicabilidad global de las escalas de evaluación. Esta es una necesidad particularmente urgente para los instrumentos nativos como el BUS, que actualmente solo ha sido validado en cuatro idiomas occidentales.

6. Vacíos de investigación

A partir de la síntesis de los 17 estudios incluidos, se identificaron siete vacíos críticos de investigación que requieren atención prioritaria en futuras investigaciones:

1. **Dependencia de encuestas post-hoc:** La mayoría de los estudios depende de encuestas retrospectivas que capturan la percepción del usuario después de la interacción. Es necesario el desarrollo de métricas a nivel de turno conversacional que permitan evaluar la experiencia en tiempo real [4]. La telemetría del diálogo y la captura de señales fisiológicas representan alternativas prometedoras para superar esta limitación.
2. **Miopía cultural:** Existe una sobre-representación significativa de demografías occidentales en la muestra de estudios revisados [1]. La validación de instrumentos de evaluación en contextos culturales diversos, particularmente en América Latina, Asia y África, es esencial para garantizar la aplicabilidad global de los hallazgos.
3. **Validaciones longitudinales:** Falta de estudios que evalúen la evolución de la experiencia del usuario a lo largo del tiempo, particularmente en lo que respecta a la disipación del efecto de novedad [2, 9]. Los usuarios podrían experimentar una satisfacción inicial alta que se degrade a medida que pierden la curiosidad por la novedad del sistema.
4. **Desconexión algoritmo-UX:** Los modelos de caja negra continúan siendo optimizados por métricas estadísticas cerradas que no necesariamente se correlacionan

con la experiencia percibida por el usuario [8]. El desarrollo de métricas que integren tanto el rendimiento algorítmico como la percepción humana es un área de investigación prioritaria.

5. **Datasets abiertos:** La disponibilidad limitada de datos privados dificulta la replicabilidad de los estudios y la comparabilidad entre investigaciones [13]. La promoción de datasets abiertos y anónimos para la investigación en evaluación UX de chatbots es esencial para el avance del campo.
6. **Explicabilidad ética:** Solo el 17.6 % de los estudios incluidos aborda explícitamente la explicabilidad algorítmica [4]. La incorporación de mecanismos de explicabilidad en el diseño de chatbots es cada vez más relevante considerando el contexto regulatorio actual y las implicaciones éticas de los sistemas conversacionales basados en IA.
7. **Entornos reales:** Predominio de estudios de laboratorio sobre estudios en entornos reales [13, 17]. La validación de instrumentos y hallazgos en contextos de uso real es necesario para garantizar la validez ecológica de los resultados.

7. Amenazas a la validez

Sesgo de selección: La búsqueda se limitó a seis bases de datos indexadas. La restricción a artículos en inglés y español, aunque justificada por recursos de traducción, limita la representatividad geográfica de la revisión.

Sesgo de publicación: Los estudios con resultados positivos tienen mayor probabilidad de ser publicados, lo que podría sobrestimar la efectividad de los instrumentos.

Restricción temporal: El periodo 2021–2026 podría no capturar la evolución completa del campo.

Restricción lingüística: La exclusión del portugués, aunque relevante para contextos latinoamericanos, se justificó por limitaciones de recursos de traducción.

Heterogeneidad de métodos: La diversidad de instrumentos dificulta la comparabilidad directa entre estudios.

Subjetividad en la selección: La selección y la extracción de datos fueron realizadas por dos revisores independientes, minimizando el sesgo individual.

8. Conclusiones

Esta revisión sistemática ha analizado 17 estudios empíricos publicados entre 2021 y 2026 sobre la evaluación de la Experiencia de Usuario en interfaces conversacionales impulsadas por IA. El análisis integral de la literatura permite identificar tanto tendencias emergentes como áreas críticas que requieren investigación adicional.

Los principales hallazgos son: (1) la literatura muestra una transición clara desde escalas genéricas (SUS) hacia instrumentos nativos como el BUS-11, lo que refleja la madurez creciente del campo; (2) la latencia algorítmica ha sido identificada como una señal social crítica con diferencias significativas entre grupos demográficos, lo que tiene implicaciones directas para el diseño adaptativo; (3) se han identificado tres capas consistentes de juicio del usuario: pragmática, socio-afectiva y de rendición de cuentas, lo que proporciona un marco teórico robusto para futuras investigaciones; (4) persisten vacíos significativos en evaluación longitudinal, adaptabilidad cultural, explicabilidad ética y validación en entornos reales; y (5) el dominio de salud y frameworks generales concentran la mayor cantidad de estudios (41.2 % cada uno).

Como contribuciones futuras se recomienda: (i) desarrollo de métricas a nivel de turno conversacional que permitan evaluar la experiencia en tiempo real; (ii) estudios longitudinales sobre la disipación del efecto de novedad y la evolución de la satisfacción del usuario; (iii) inclusión de poblaciones sub-representadas en América Latina, particularmente la validación de instrumentos en contextos culturales latinoamericanos; y (iv) adopción de marcos de evaluación unificados que integren tanto métricas algorítmicas como perceptuales.

La presente revisión proporciona una base teórica y metodológica sólida para investigadores y profesionales interesados en la evaluación UX de sistemas conversacionales. La identificación de instrumentos nativos validados, la caracterización de las dimensiones de evaluación relevantes y la identificación de vacíos de investigación críticos contribuye al avance del conocimiento en un campo en rápido crecimiento.

9. Agradecimientos

Los autores agradecen a la Facultad de Ingeniería de Sistemas e Informática de la Universidad Nacional Mayor de San Marcos por el apoyo brindado para la realización de esta investigación. Asimismo, se agradece a la comunidad académica que contribuyó con retroalimentación constructiva durante el desarrollo de este trabajo.

Referencias

- [1] Følstad, A., Araujo, T., Law, E., et al. (2021). Future directions for chatbot research. *Computing*, 103, 2915–2942. DOI: 10.1007/s00607-021-01016-7
- [2] Kuhail, M. A., Alturki, N., Alramlawi, S., y Alhejori, K. (2022). Interacting with educational chatbots: A systematic review. *Education and Information Technologies*, 28, 973–1018. DOI: 10.1007/s10639-022-11177-3
- [3] Belda-Medina, J., y Kokošková, V. (2023). Integrating chatbots in education: Insights from CHISM. *Int. J. Educational Technology in Higher Education*, 20, 1–20. DOI: 10.1186/s41239-023-00432-3
- [4] Marconi, L., Longo, L., y Cabitza, F. (2026). Assessing interaction quality in human–AI dialogue. *Machine Learning and Knowledge Extraction*, 8(2), 28. DOI: 10.3390/make8020028
- [5] Borsci, S., Malizia, A., Schmettow, M., et al. (2021). The Chatbot Usability Scale. *Personal and Ubiquitous Computing*, 26, 95–119. DOI: 10.1007/s00779-021-01582-9
- [6] Wang, Y.-L., y Lo, C.-W. (2025). Effects of response time on chatbot interaction experience. *BMC Psychology*, 13. DOI: 10.1186/s40359-025-02459-9
- [7] Brdnik, S., Heričko, T., y Šumak, B. (2022). Intelligent user interfaces: A systematic mapping study. *Sensors*, 22, 5830. DOI: 10.3390/s22155830
- [8] Jannach, D. (2022). Evaluating conversational recommender systems. *Artificial Intelligence Review*, 56, 2365–2400. DOI: 10.1007/s10462-022-10229-x
- [9] Borsci, S., Schmettow, M., Malizia, A., et al. (2022). BUS-11: A multilanguage validation. *Personal and Ubiquitous Computing*, 27, 317–330. DOI: 10.1007/s00779-022-01690-0
- [10] He, L., Basar, E., Wiers, R. W., et al. (2022). Can chatbots help to motivate smoking cessation? *BMC Public Health*, 22(1), 726. DOI: 10.1186/s12889-022-13115-x
- [11] Bielawski, K., y Batorski, D. (2022). Sensors and AI methods for HCII: A systematic mapping. *Sensors*, 22(1), 20. DOI: 10.3390/s22010020
- [12] Roick, T., y Jansen, S. (2023). A motivational interviewing chatbot. *JMIR Mental Health*, 10, e49132. DOI: 10.2196/49132
- [13] Fan, X., Chao, D., Zhang, Z., et al. (2023). Self-diagnosis health chatbots in real-world settings. *JMIR mHealth and uHealth*, 11, e43045. DOI: 10.2196/43045
- [14] Chung, K., Cho, H. Y., y Park, J. Y. (2021). A chatbot for perinatal women’s mental health care. *JMIR Medical Informatics*, 9(3), e18607. DOI: 10.2196/18607
- [15] Mariamo, A., Temcheff, C. E., Léger, P.-M., et al. (2021). Emotional reactions to mental health chatbot questions among adolescents. *JMIR Human Factors*, 8(1), e24343. DOI: 10.2196/24343
- [16] Chou, Y.-H., Lin, C., Lee, S.-H., et al. (2024). User-friendly chatbot for older adults during COVID-19. *JMIR Formative Research*, 8, e49462. DOI: 10.2196/49462
- [17] Thunström, A. O., Carlsen, H. K., Ali, L., et al. (2024). Usability comparison: Digital human vs. chatbot for mental health. *JMIR Human Factors*, 11, e54581. DOI: 10.2196/54581
- [18] Brooke, J. (1996). SUS: A “quick and dirty” usability scale. En *Usability Evaluation in Industry*, pp. 189–194. Taylor y Francis.
- [19] Page, M. J., McKenzie, J. E., Bossuyt, P. M., et al. (2021). The PRISMA 2020 statement. *BMJ*, 372, n71. DOI: 10.1136/bmj.n71
- [20] Kitchenham, B., Madeyski, L., y Budgen, D. (2023). SEGRESS: Guidelines for reporting secondary studies. *IEEE Trans. Software Engineering*, 49(3), 1273–1298. DOI: 10.1109/TSE.2022.3174092

A. Resumen detallado de estudios incluidos

La Tabla 8 presenta el resumen completo de los 17 estudios incluidos en la revisión sistemática.

Tabla 8: Resumen de los 17 estudios incluidos.

Autor (Año)	Dominio	Instrumento	Hallazgo principal
Følstad et al. (2021)	General	SUS	Agenda de investigación para chatbots
Kuhail et al. (2022)	Educación	SUS	36 papers; chatbots como tutores web
Belda-Medina (2023)	Educación	CHISM	237 estudiantes; percepciones AIC
Marconi et al. (2026)	General	Framework CALO	125 estudios; marco de 4 capas
Borsci et al. (2021)	General	BUS-15	Diseño de escala para chatbots
Wang y Lo (2025)	General	Likert ad-hoc	Latencia influye según la edad
Brdnik et al. (2022)	General	N/A	Interfaces inteligentes evaluadas
Jannach (2022)	Sistemas de recomendación	UMUX-LITE	Evaluación de recomendadores
Borsci et al. (2022)	General	BUS-11	Validación multilingüe; 11 ítems
He et al. (2022)	Salud	BOT-Check	Chatbot entrevista motivacional
Bielawski (2022)	General	N/A	Métodos HCII: sensores e IA
Roick y Jansen (2023)	Salud	Likert ad-hoc	Chatbot motivacional iterativo
Fan et al. (2023)	Salud	Likert ad-hoc	Uso real chatbots autodiagnóstico
Chung et al. (2021)	Salud	Likert ad-hoc	Chatbot perinatal Q&A
Mariamo et al. (2021)	Salud	Likert ad-hoc	Reacciones adolescentes
Chou et al. (2024)	Salud	Likert ad-hoc	Chatbot adultos mayores COVID
Thunström et al. (2024)	Salud	SUS	Humano digital vs. chatbot texto

Nota: N/A indica que el estudio es de mapeo y no aplica instrumentos de evaluación UX directamente.